

Previsão de atrasos no nível do voo

VRA/ANAC reconstruído, 2000–2013 · validação temporal de origem rolante (DECISIONS.md, ADR-0009) · alvo principal `late15_arr` (arrival more than 15 minutes late)

10.200.560 voos programados · 14 anos · xgboost, hist · commit 14d12b6 · gerado em 2026-09-05T04:48:48-0300

O que está sendo previsto, e para quem

Duas perguntas diferentes, respondidas separadamente porque misturá-las é o erro clássico da literatura de previsão de atrasos:

D-1 (véspera) o que um planejador sabe na noite anterior — malha programada, calendário, estrutura de mercado e histórico de janela fechada. 46 variáveis.

H-1 (portão) acrescenta o resultado da *etapa anterior* do mesmo número de voo no mesmo dia — o atraso real com que ela chegou, se foi cancelada, se passou de 15 minutos. 49 variáveis. Nada do próprio voo.

A unidade é o voo *programado* do universo de replicação (ADR-0002: tipos de linha N, R, E e DI 0), realizado ou cancelado. O alvo de cancelamento existe em toda linha; os alvos de atraso existem só onde há horário real, e é aí que está a característica mais importante desta base.

O horário real vazio: “sem alteração reportada” (ADR-0017)

Nos arquivos brutos de 2000 a 2009 o horário realizado é campo do Boletim de Alteração de Voo, emitido pela IAC 1504 só “sempre que houver alguma alteração” (introdução e §3.1; horários e código de justificativa em §4.2 n, o, p). Campo vazio em voo realizado é, portanto, *ausência de alteração reportada*, e não desfecho desconhecido. Um colegiado de três revisores (ADR-0010, pareceres em docs/notes/colegiado-adr0012.md) adotou essa leitura; o atraso vale 0 e a linha recebe a marca `on_time_no_bav`.

O escopo não é o arquivo inteiro. A taxa de nulo não é uma convenção só: de 2000 a 2009 é de 72,9% nos 5,1 milhões de voos realizados dentro do escopo e de 83,0% nos 313.368 fora dele, e o revisor cético mediu 90–100% em estrangeiras e trechos de code-share num corte de 2005 sobre todos os voos (tabela por empresa e ano em docs/declared-differences.md). A IAC 1504 art. 6.6 diz que em code-share só a operadora presta a informação. A leitura vale, então, apenas para voos realizados de empresas de classe FSC, LCC ou regional em `groups.csv`; para `other` e não rotuladas o vazio continua desconhecido e o voo fica *fora de escopo*, sem alvo de atraso.

ano	voos programados	com alvo	sem alteração	share dos realizados	fora de escopo (ADR-0017)	horário (ADR-0015)	taxa > 15 min	chegada anterior conhecida
2000	659.299	553.524	437.035	74,5%	33.239	242	19,1%	83,6%
2001	691.578	581.668	434.010	71,1%	28.903	101	21,9%	84,1%
2002	678.949	535.107	404.732	71,7%	29.215	53	21,3%	79,6%
2003	565.658	410.046	311.863	72,3%	20.554	1.032	18,0%	73,7%
2004	536.553	438.565	328.488	72,0%	17.460	296	19,9%	81,1%
2005	552.055	455.094	317.219	66,6%	20.724	373	25,6%	80,7%
2006	588.640	465.175	311.100	63,0%	28.584	94	30,2%	78,1%
2007	641.630	477.330	268.009	52,2%	35.503	247	41,1%	73,2%
2008	663.781	574.534	395.495	65,9%	25.417	170	28,6%	85,0%
2009	756.194	665.407	512.806	74,7%	20.589	220	20,2%	87,0%
2010	874.236	796.359	0	0,0%	146	417	24,3%	91,8%
2011	983.054	898.116	0	0,0%	145	643	24,5%	92,1%
2012	1.023.977	942.102	0	0,0%	115	370	21,5%	91,4%
2013	984.956	893.670	0	0,0%	11	990	16,3%	91,1%

A leitura B é um *piso de pontualidade*: atraso não reportado conta como pontual, então a taxa anterior a 2010 é limite inferior. A alternativa não é neutra — a leitura A condiciona no desfecho, guardando só os voos que tiveram ocorrência,

e produzia uma taxa-base de 91,1% em 2006 contra 24,3% em 2010, degrau que nasce na fronteira de layout e não na operação; sob a leitura B os mesmos dois folds ficam em 30,2% e 24,3%. A comparação completa está na seção 4.3. A quebra de 2010 continua sendo quebra de comparabilidade: de 2010 em diante praticamente todo voo realizado traz horário real, e antes disso não.

A regra da ADR-0015 é pequena ao lado dessa — cerca de 5,2 mil voos em toda a série — mas tira os piores rótulos: um atraso de 43.170 minutos é erro de digitação de mês, e treinar contra ele é treinar contra o cartório. Desde esta fase a marca vem do próprio staging, na coluna `actual_time_suspect`.

Resultado principal: origem rolante

Treina até $y - 2$, escolhe o número de árvores em $y - 1$ (parada antecipada) e testa em y . As duas referências ingênuas da ADR-0009 são a prevalência da rota e a do grupo aéreo no mês anterior, com recuo para a taxa-base do treino onde o mês anterior não observou nada.

ano	n teste	base	D-1			H-1			rota $t - 1$		grupo
			AUC	PR-AUC	Brier	AUC	PR-AUC	Brier	AUC	Brier	AUC
2006	465.175	30,2%	0,728	0,521	0,191	0,821	0,723	0,148	0,673	0,195	0,641
2007	477.330	41,1%	0,741	0,645	0,206	0,824	0,788	0,167	0,647	0,227	0,609
2008	574.534	28,6%	0,729	0,518	0,178	0,793	0,658	0,154	0,648	0,194	0,629
2009	665.407	20,2%	0,728	0,450	0,141	0,786	0,569	0,124	0,639	0,154	0,640
2010	796.359	24,3%	0,724	0,460	0,162	0,790	0,610	0,141	0,624	0,179	0,621
2011	898.116	24,5%	0,716	0,464	0,163	0,777	0,599	0,144	0,611	0,181	0,595
2012	942.102	21,5%	0,719	0,426	0,150	0,765	0,541	0,136	0,608	0,165	0,549
2013	893.670	16,3%	0,715	0,348	0,124	0,757	0,464	0,113	0,613	0,134	0,566

Três leituras. *Primeiro*, o horizonte H-1 ganha em todos os anos, e o ganho é grande justamente onde a base é baixa — a informação da etapa anterior é o que a malha programada não tem. *Segundo*, as referências ingênuas não são espantinhos: a prevalência da rota no mês anterior já ordena os voos bem acima do acaso, e é contra ela, não contra 0,5, que o modelo precisa ser lido. *Terceiro*, sob a leitura B da ADR-0017 a taxa-base é da mesma ordem em toda a série, e o degrau de 2009 → 2010 que a leitura A produzia desapareceu: os folds passam a ser comparáveis entre si, o que é a condição para que a origem rolante signifique alguma coisa. O que sobra de variação entre folds é operação, não troca de amostra.

Só onde existe etapa anterior ligada

O H-1 só diz algo onde a etapa anterior existe. Os dois horizontes são reavaliados exatamente nessas linhas, para que a diferença seja o horizonte e não a população.

ano	share ligado	n ligado	AUC D-1	AUC H-1	Brier D-1	Brier H-1
2006	35,1%	163.136	0,730	0,924	0,199	0,086
2007	34,3%	163.788	0,760	0,934	0,203	0,091
2008	30,1%	173.131	0,750	0,910	0,179	0,098
2009	29,2%	194.630	0,726	0,891	0,145	0,087
2010	29,4%	233.841	0,713	0,897	0,166	0,094
2011	28,7%	258.137	0,707	0,881	0,170	0,103
2012	25,0%	235.399	0,713	0,869	0,159	0,101
2013	19,8%	177.265	0,705	0,870	0,138	0,086

Aqui o horizonte aparece pelo que é: o ganho no subconjunto ligado é bem maior que na tabela anterior, onde ele fica diluído pelos 61% a 80% de voos sem elo identificável.

Sensibilidade: leitura A ao lado da leitura B

A leitura A, superada pela ADR-0017, tratava horário real vazio como *desconhecido*. As colunas “A” abaixo vêm da rodada anterior, preservada em `reports/prediction/rolling_reading_A.json`; nada foi reestimado sob a

convenção superada. De 2010 em diante as duas leituras enxergam o mesmo dado, e só aí a comparação é de igual para igual — antes de 2010 muda a *população de teste*, e a taxa-base diz isso.

ano	<i>n</i> A	<i>n</i> B	base A	base B	AUC D-1 A	AUC D-1 B	AUC H-1 A	AUC H-1 B
2006	154.073	465.175	91,1%	30,2%	0,810	0,728	0,864	0,821
2007	209.328	477.330	93,6%	41,1%	0,788	0,741	0,840	0,824
2008	179.046	574.534	91,8%	28,6%	0,761	0,729	0,803	0,793
2009	152.604	665.407	88,3%	20,2%	0,767	0,728	0,804	0,786
2010	796.389	796.359	24,3%	24,3%	0,638	0,724	0,736	0,790
2011	898.100	898.116	24,5%	24,5%	0,636	0,716	0,735	0,777
2012	942.104	942.102	21,5%	21,5%	0,698	0,719	0,754	0,765
2013	893.657	893.670	16,3%	16,3%	0,711	0,715	0,749	0,757

Split fixo (ilustrativo)

Treino 2002–2010, validação 2011, teste 2012–2013 — o desenho que a literatura usa. É reportado porque é comparável, não porque é a melhor resposta: um único corte não mostra o que 2007 e 2013 fazem com um modelo treinado no outro.

alvo	<i>n</i> teste	base	D-1			H-1		
			AUC	PR-AUC	Brier	AUC	PR-AUC	Brier
late15_arr	1.835.772	18,9%	0,720	0,396	0,137	0,762	0,506	0,126
late30_arr	1.835.772	9,0%	0,704	0,207	0,078	0,765	0,373	0,069
late15_dep	1.835.772	16,4%	0,676	0,297	0,129	0,744	0,463	0,114
cancelled	2.008.933	8,5%	0,723	0,233	0,073	0,791	0,392	0,065

Calibração

Probabilidade prevista contra frequência observada, no último fold da origem rolante. Um modelo bem calibrado tem as duas colunas iguais.

faixa de probabilidade	<i>n</i>	share	média prevista	observado
0,0–0,1	273.927	30,7%	0,068	0,063
0,1–0,2	346.502	38,8%	0,145	0,134
0,2–0,3	158.407	17,7%	0,243	0,227
0,3–0,4	65.932	7,4%	0,342	0,331
0,4–0,5	28.329	3,2%	0,444	0,434
0,5–0,6	12.141	1,4%	0,542	0,519
0,6–0,7	5.076	0,6%	0,644	0,604
0,7–0,8	2.369	0,3%	0,740	0,679
0,8–0,9	757	0,1%	0,840	0,696
0,9–1,0	230	0,0%	0,936	0,543

Fold rolling_2013, horizonte D-1. As faixas do H-1 estão em `reports/prediction/calibration.json`.

O que o modelo usa

Queda na AUC de teste quando a coluna é embaralhada, média de 3 repetições sobre até 250.000 linhas do último fold. O ganho total do XGBoost está ao lado porque os dois discordam de um jeito legível: ganho premia a variável que é *usada*, permutação premia a variável de que a métrica *depende*.

D-1

variável	queda AUC	dp
flight_no_late15_l3	0,1060	0,0007

H-1

variável	queda AUC	dp
flight_no_late15_l3	0,0728	0,0002

sched_block_min	0,0607	0,0002
distance_km	0,0373	0,0003
month	0,0139	0,0004
origin_movements_hour	0,0119	0,0004
dow	0,0091	0,0001
route_late15_l1	0,0069	0,0002
sched_dep_hour	0,0059	0,0003
origin_icao	0,0051	0,0002
dest_icao	0,0027	0,0002

sched_block_min	0,0710	0,0002
distance_km	0,0505	0,0002
prev_arr_delay_min	0,0476	0,0003
prev_turnaround_min	0,0172	0,0001
origin_movements_hour	0,0155	0,0002
month	0,0116	0,0002
dow	0,0067	0,0001
origin_icao	0,0058	0,0003
route_late15_l1	0,0052	0,0002

Três coisas no ranking. O histórico do *próprio número de voo* nos três meses anteriores é a variável isolada mais forte do D-1 e a segunda do H-1: a malha carrega atraso estrutural por horário e por trecho, e o número de voo é o identificador mais fino que existe sem tipo de aeronave. O bloco previsto e a distância vêm logo atrás nos dois horizontes, e são quase a mesma informação — o bloco é distância mais folga, e é a folga que carrega o sinal. E `prev_arr_delay_min` aparece só em 4° no H-1, muito abaixo do que a tabela do subconjunto ligado mostra: `prev_late15` é o mesmo sinal binarizado, e embaralhar uma variável deixando a substituta intacta subestima as duas. Importância por permutação mede o que é *insubstituível*, não o que importa; para o valor do horizonte, a comparação das duas tabelas da seção anterior é a medida certa.

A regra de vazamento, e as checagens que a impõem

A regra foi escrita antes da primeira variável (ADR-0009): nada do próprio voo posterior à decolagem; nenhum agregado do mesmo mês que contenha o voo; janelas históricas fechadas antes da data do voo. As nove checagens de `ml/leakage_tests.py` rodam sobre a base real (anos 2000 e 2013) e, no `pytest`, sobre a amostra versionada em `tests/fixtures/`.

	checagem	o que foi medido
ok	<code>features_exclude_post_departure</code>	49 features checked against 13 forbidden names and 3 prefixes
ok	<code>targets_are_not_features</code>	5 targets and 6 diagnostics kept out of both horizons
ok	<code>horizons_are_nested</code>	H-1 adds ['prev_arr_delay_min', 'prev_late15', 'prev_cancelled'] to D-1's 46 features
ok	<code>lag_windows_closed</code>	over 1,535,464 rows where t-1 and t differ: 1.0000 match t-1, 0.0000 match t (pandas 2.3.3)
ok	<code>movements_from_schedule</code>	1.0000 of 1,644,255 rows match a recount from sched_dep/sched_arr (a dataset reusing the staged dep_hour, which falls back to actual_dep, would not)
ok	<code>previous_leg_precedes_departure</code>	453,524 linked legs, 0 with a negative turnaround, 0 with none, 0 turnarounds on unlinked flights
ok	<code>targets_null_without_actual</code>	33,250 realised flights out of scope for reading B keep no arrival target (ADR-0017), 437,035 are read as no alteration reported, and 1,232 suspect timestamps are excluded (ADR-0015); 0 rows disagreeing
ok	<code>first_year_has_no_p90</code>	2000: 0 rows carry a p90 flag (must be 0); later years: 983,970 of 984,956
ok	<code>calendar_matches_the_table</code>	92 dated holidays, 27,404 flagged flights, 0 wrong

Duas delas merecem destaque. `movements_from_schedule` reconta os movimentos por aeroporto-dia-hora a partir do horário *previsto* no `data/staged/`: a coluna `dep_hour` da camada `staged` recorre ao horário *real* quando o previsto falta, e uma base que a reutilizasse carregaria hora pós-decolagem sem que nada quebrassem. `lag_windows_closed` compara cada `route_late15_l1` com a taxa da rota em $t-1$ e em t , e exige que bata com a primeira e não com a segunda — é a forma executável do vazamento que este repositório já mediu em si mesmo, quando o `fsc_prdeldep` do mesmo mês levou um R^2 de painel de 0,58 para 0,82.

Limites declarados

1. **A leitura B é um piso, e o instrumento muda em 2010.** Antes de 2010 o alvo vem do Boletim de Alteração de Vôo: atraso não reportado conta como pontual, e a taxa publicada é limite inferior. De 2010 em diante quase todo voo realizado traz horário real. A tabela da seção 2 traz a marca `on_time_no_bav` por ano para que a diferença de instrumento fique visível, e a seção 4.3 traz as métricas sob a leitura A ao lado.
2. **Empresas de classe other ficam sem alvo antes de 2010.** A leitura B não as cobre (IAC 1504 art. 6.6, code-share), e a auditoria que decidiria se esses trechos devem sair dos universos por completo é candidata a ADR-0018.

3. **H-1 é o horizonte da ADR-0009, não um relógio.** A etapa anterior pode pousar depois do corte de uma hora; a base carrega `prev_arr_known_h1` e o `manifest.json` reporta a fração por ano. A variável não é anulada, porque a definição do horizonte é decisão registrada, não estimativa.
4. **Sem meteorologia.** O METAR do DECEA/REDEMETS não entra nesta fase; o que existe é a participação de códigos de clima no aeroporto no mês anterior, que é climatologia defasada, não previsão do tempo.
5. **Sem capacidade declarada.** A hora cheia é o proxy p90 da ADR-0007 com a janela fechada no ano anterior. `data/external/capacity.csv` tem uma linha, e uma linha não sustenta um painel nacional.
6. **Sem tipo de aeronave nem assentos.** Só existem no layout de 2010 em diante, e uma variável que nasce no meio da série quebra a validação temporal.

Hiperparâmetros, idênticos em todos os folds e nos dois horizontes: `hist`, profundidade 7, taxa 0,08, até 1200 árvores com parada antecipada em 40 rodadas, `max_bin` 128, subamostra 0,8. A base tem 10.200.560 linhas e é reconstruída em 25 segundos por `just ml-dataset`. Reprodução completa: `just ml`.